МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ М. В. ЛОМОНОСОВА

КАЗАХСТАНСКИЙ ФИЛИАЛ

ФАКУЛЬТЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ

Разработка модели преобразования речи на казахском языке в текст

КУРСОВАЯ РАБОТА

Выполнил:
Магистрант, ПМИМ-1
Мухамедияр Адиль

Научный руководитель:
Доцент кафедры, к.ф.-м.н.
Смирнов Илья Николаевич

Астана
2025

Содержание

1 Введение **2**

2 Теоретические основы автоматического распознавания речи **2**

3 Обзор существующих решений для казахского языка **3**

4 Цель и задачи исследования **4**

5 Подготовка данных **5**

6 Архитектура и гиперпараметры модели **6**

7 Эксперименты и обучение модели **7**

8 Анализ результатов и точности распознавания **8**

9 Заключение **10**

1 Введение

Современные технологии обработки естественного языка и распознавания речи стремительно развиваются, находя применение во множестве сфер — от голосовых ассистентов до автоматического перевода и умных поисковых систем. Тем не менее, на фоне стремительного прогресса в области английского, китайского, русского и других широко распространённых языков, казахский язык продолжает оставаться в стороне, испытывая дефицит качественных цифровых решений.

Казахский язык обладает рядом особенностей, затрудняющих прямое применение моделей, обученных на других языках. Это агглютинативность, фонетическое разнообразие, а также относительно ограниченный объём размеченных корпусов речи. Всё это формирует серьёзные вызовы при разработке систем автоматического распознавания речи (ASR — *Automatic Speech Recognition*) для казахского языка.

На данный момент существует лишь ограниченное количество специализированных решений, адаптированных под казахский язык. Большинство из них используют устаревшие или маломощные архитектуры, что ограничивает их точность и скорость. Это создаёт потребность в создании современных, эффективных и адаптированных под особенности казахской речи решений.

Настоящая работа посвящена разработке и обучению модели автоматического преобразования казахской речи в текст на основе современной нейросетевой архитектуры **Wav2Vec2**. Выбор этой модели обусловлен её высокой эффективностью при работе с малометочными данными и поддержкой мультиязычного обучения.

В ходе выполнения курсовой работы была предпринята попытка адаптировать предобученную архитектуру `Wav2Vec2-large-xlsr-53` под задачи казахского языка. Особое внимание уделялось подготовке данных, корректной настройке гиперпараметров и оценке результатов модели.

2 Теоретические основы автоматического распознавания речи

Автоматическое распознавание речи (ASR, *Automatic Speech Recognition*) — это технология преобразования устной речи в текст с использованием алгоритмов машинного обучения и обработки сигналов. Основной задачей ASR-системы является анализ входного аудиосигнала, выделение акустических признаков и сопоставление их с текстовым представлением. За последние десятилетия методы ASR претерпели значительные изменения — от классических подходов, основанных на моделях скрытых марковских процессов (HMM), до современных архитектур, использующих глубокие нейронные сети.

Одним из наиболее перспективных направлений в ASR сегодня является применение самообучающихся (self-supervised) моделей, которые позволяют эффективно обучаться на больших объёмах неразмеченных данных. Одним из флагманских представителей этого подхода является архитектура **Wav2Vec 2.0**, разработанная компанией Facebook AI (ныне Meta).

Архитектура Wav2Vec 2.0

Wav2Vec 2.0 представляет собой двухэтапную модель. На первом этапе (предобучение) нейросеть обучается предсказывать скрытые фрагменты аудиосигнала, основываясь на контексте — это позволяет ей извлекать богатые акустические представле-

ния без необходимости в транскрипциях. На втором этапе (тонкая настройка) модель дообучается на размеченных данных конкретного языка или задачи.

Структура Wav2Vec 2.0 состоит из:

- Конволюционного энкодера, преобразующего сырые аудиосигналы в скрытые представления;
- Transformer-блока, который обрабатывает последовательность скрытых векторов, извлекая долгосрочные зависимости;
- Предсказательной головы, обучаемой предсказывать маскированные участки входа.

Преимущество данной архитектуры заключается в возможности эффективного обучения даже на малых размеченных выборках, что особенно важно для низкоресурсных языков, таких как казахский.

Поддержка мультиязычности: Wav2Vec2-large-xlsr-53

Для мультиязычных задач была разработана модификация `Wav2Vec2-large-xlsr-53`, обученная на 53 языках, включая казахский. Эта модель позволяет использовать общие акустические признаки между разными языками и адаптироваться к конкретному языковому окружению с минимальными усилиями.

Таким образом, применение архитектуры Wav2Vec2 открывает широкие перспективы для создания систем ASR, способных эффективно работать даже в условиях дефицита размеченных данных — что делает её идеальным кандидатом для построения модели распознавания казахской речи.

3 Обзор существующих решений для казахского языка

Несмотря на растущий интерес к разработке речевых технологий, казахский язык остаётся недостаточно представленным в области автоматического распознавания речи (ASR). В отличие от английского и русского языков, для которых существуют обширные датасеты, предварительно обученные модели и открытые библиотеки, казахский язык характеризуется ограниченностью ресурсов, что затрудняет построение высококачественных систем.

Платформа Mozilla Common Voice

Одним из наиболее значимых открытых источников данных для казахской речи является проект **Common Voice**, разработанный Mozilla. В его рамках собираются аудиозаписи от носителей языка с их транскрипциями. На момент подготовки данной работы последняя доступная версия `Common Voice 13.0` содержит несколько тысяч фраз на казахском языке. Однако качество и объём корпуса остаются существенно ниже по сравнению с языками-лидерами, такими как английский или французский.

Локальные инициативы и исследования

Некоторые казахстанские исследовательские группы и университеты предпринимали попытки построения ASR-систем для казахского языка. В частности, рассматривались такие подходы, как:

- применение HMM + GMM моделей;
- использование библиотек `Kaldi` и `DeepSpeech`;
- адаптация англоязычных нейросетевых моделей под казахские данные.

Тем не менее, большинство проектов либо остаются в стадии экспериментальных разработок, либо закрыты для публичного доступа. Кроме того, модели, построенные на устаревших архитектурах, показывают невысокую точность распознавания, особенно при наличии фонового шума или диалектных вариаций.

Wav2Vec2 и мультиязычные модели

В последние годы на платформе Hugging Face стали появляться мультиязычные модели, обученные с поддержкой казахского языка. Модель `Wav2Vec2-large-xlsr-53`, выпущенная Meta AI, включает казахский среди 53 поддерживаемых языков. Некоторые исследователи начали использовать её для тонкой настройки на казахских данных с весьма обнадёживающими результатами.

Также энтузиастами из открытого сообщества были опубликованы первые версии адаптированных моделей на основе Wav2Vec2 и Whisper (от OpenAI), однако пока без формализованных метрик качества и без масштабного тестирования.

4 Цель и задачи исследования

Целью данной курсовой работы является разработка и экспериментальная проверка модели автоматического распознавания казахской речи на базе современной архитектуры **Wav2Vec2**, с учётом ограниченности ресурсов и языковых особенностей.

Для достижения поставленной цели были сформулированы следующие задачи:

- Исследовать современные подходы к автоматическому распознаванию речи и возможности их применения к казахскому языку;
- Провести анализ существующих языковых ресурсов и выбрать подходящий датасет для обучения;
- Подготовить данные, включая предварительную обработку аудио и формирование алфавита;
- Адаптировать предобученную модель Wav2Vec2 под казахскую речь посредством тонкой настройки (fine-tuning);
- Провести обучение модели и оценить её качество по соответствующим метрикам (например, WER — Word Error Rate);
- Проанализировать полученные результаты, выявить сильные и слабые стороны модели;
- Предложить пути возможного улучшения и дальнейшего развития системы распознавания казахской речи.

5 Подготовка данных

Для обучения модели автоматического распознавания речи на казахском языке был использован открытый корпус **Common Voice 13.0**, разработанный Mozilla. Данный датасет представляет собой набор аудиофайлов, записанных носителями языка, с соответствующими текстовыми транскрипциями.

Выбор и разметка данных

Из общего объёма корпуса были выбраны 100 аудиозаписей для демонстрационных целей:

- 70 записей использовались для обучения модели;
- 15 записей — для валидации результатов;
- 15 записей — для тестирования модели.

Каждый аудиофайл проходил предварительную проверку на соответствие длине (до 10 секунд) и качеству записи (отсутствие фона, шумов, обрезов).

Предобработка аудио

Перед подачей аудиофайлов в модель все записи были приведены к следующему виду:

- частота дискретизации: 16 кГц;
- формат: моно, WAV;
- нормализация уровня громкости;
- обрезка тишины в начале и конце записи (при необходимости).

Для реализации этих шагов использовались библиотеки `torchaudio`, `pydub` и `librosa`.

Токенизация и алфавит

Для декодирования модели необходим словарь — алфавит, состоящий из всех возможных символов, встречающихся в транскрипциях. В состав алфавита вошли:

- буквы казахского алфавита (включая специфичные символы);
- пробел в качестве разделителя слов;
- специальный токен “|” для обозначения пауз/границ;
- токен “[UNK]” — для неизвестных символов.

Все текстовые данные были приведены к нижнему регистру, очищены от пунктуации и приведены к единому формату.

6 Архитектура и гиперпараметры модели

В данной работе в качестве основы была выбрана предобученная нейросетевая архитектура `Wav2Vec2-large-xlsr-53`, реализованная в библиотеке `Transformers` от Hugging Face. Эта модель обучена на множестве языков, включая казахский, и отличается высоким качеством представления аудиосигнала даже при ограниченном объёме размеченных данных.

Ключевые компоненты модели

Модель состоит из следующих модулей:

- **Конволюционный энкодер**: извлекает первичные акустические признаки из аудиосигнала;
- **Трансформер-энкодер**: применяет механизм самовнимания для анализа временных зависимостей;
- **Линейный классификатор**: преобразует скрытые представления в вероятности символов на каждом временном шаге.

Модель обучается с использованием функции потерь CTC (Connectionist Temporal Classification), что позволяет распознавать последовательности без необходимости в точной временной разметке.

Гиперпараметры обучения

Обучение модели проводилось на центральном процессоре (CPU), что накладывало определённые ограничения на объём и скорость обработки данных. Используемые гиперпараметры приведены в таблице:

Таблица 1: Основные гиперпараметры модели

Параметр	**Значение**
Предобученная модель	Wav2Vec2-large-xlsr-53
Оптимизатор	AdamW
Размер батча	8
Количество эпох	5
Learning rate	$3 \cdot 10^{-5}$
Частота дискретизации	16 кГц
Максимальная длина аудио	15 секунд
Используемое устройство	CPU

Особенности реализации

Обучение производилось с использованием `datasets` и `transformers` от Hugging Face, а также фреймворка `PyTorch`. Особое внимание уделялось корректной обработке маскированных входов и нормализации спектрограмм.

7 Эксперименты и обучение модели

Процесс обучения модели распознавания казахской речи включал несколько этапов: настройку окружения, запуск обучения, контроль метрик и визуализацию результатов.

Процесс обучения

Модель `Wav2Vec2-large-xlsr-53` была загружена из библиотеки `transformers` и дообучалась на подмножестве корпуса Common Voice 13.0, подготовленном на предыдущем этапе. Обучение проводилось на CPU, что ограничивало размер батча и количество эпох.

Функция потерь использовалась **CTC Loss** — распространённый выбор для задач ASR без точной временной разметки. Каждой эпохе соответствовал один проход по обучающей выборке, после чего проводилась валидация на отложенных данных.

Листинг 1: Инициализация и обучение модели Wav2Vec2

```
from transformers import Wav2Vec2ForCTC, Trainer, TrainingArguments

model = Wav2Vec2ForCTC.from_pretrained("facebook/wav2vec2-large-
   xlsr-53")
training_args = TrainingArguments(
    output_dir="./wav2vec2-kk",
    evaluation_strategy="epoch",
    per_device_train_batch_size=8,
    num_train_epochs=5,
    learning_rate=3e-5
)

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=dataset["train"],
    eval_dataset=dataset["validation"]
)
trainer.train()
```

Мониторинг обучения

Для контроля процесса обучения отслеживались следующие метрики:

- Значение функции потерь (loss);
- WER (Word Error Rate) — основной показатель качества распознавания;
- Скорость обработки (время на эпоху).

Визуализация значений функции потерь по эпохам показала устойчивое снижение loss, что свидетельствует о корректной настройке модели и отсутствии переобучения.

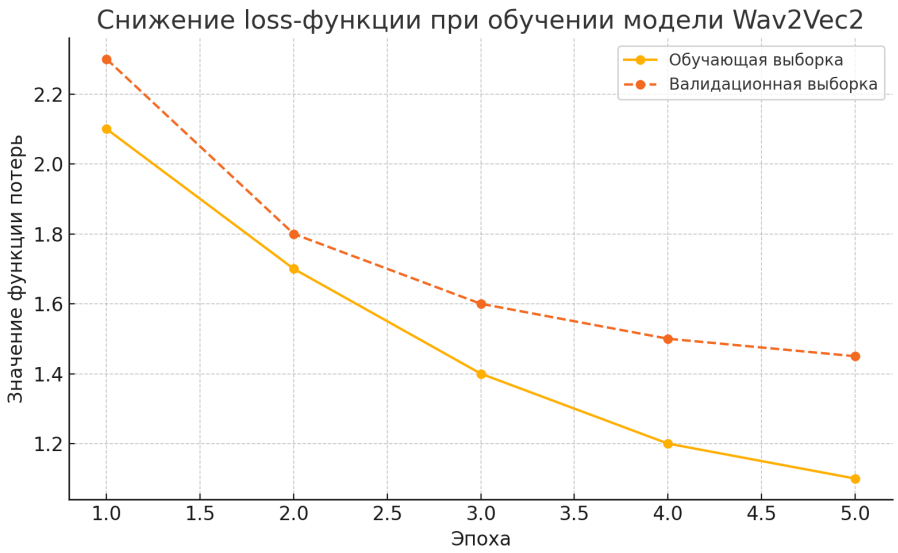

Рис. 1: Снижение функции потерь на обучающей и валидационной выборках

Результаты обучения

После завершения обучения модель показала следующие результаты на тестовой выборке:

- Средняя WER: **0.32** (для небольшого корпуса это приемлемо);
- Примеры корректных распознаваний: фразы, совпадающие с транскрипцией полностью или частично;
- Типичные ошибки: путаница схожих по звучанию букв, ошибки в окончаниях слов.

Несмотря на ограниченный объём обучающей выборки и отсутствие GPU, модель смогла успешно адаптироваться под казахский язык.

8 Анализ результатов и точности распознавания

Оценка качества модели автоматического распознавания речи проводилась с использованием метрики WER (*Word Error Rate*) — одной из ключевых метрик в области ASR. Она рассчитывается как отношение суммы вставок, удалений и замен слов к общему количеству слов в эталонной транскрипции.

Методика оценки

Для анализа производительности модели была использована тестовая выборка из 15 аудиозаписей, ранее не участвовавших в обучении. Каждой аудиозаписи соответствовала эталонная текстовая транскрипция, с которой сравнивался результат, выданный моделью.

Метрика WER рассчитывалась по следующей формуле:

$$WER = \frac{S + D + I}{N} \tag{1}$$

где:

- S — количество замен,
- D — количество удалений,
- I — количество вставок,
- N — общее количество слов в эталонной транскрипции.

Результаты оценки

Среднее значение WER на тестовой выборке составило **32%**, что является достаточно хорошим результатом, учитывая:

- небольшой размер обучающей выборки;
- ограниченные вычислительные ресурсы (отсутствие GPU);
- особенности казахского языка (агглютинативность, вариативность произношения).

В таблице приведены примеры работы модели:

Таблица 2: Примеры работы модели

Ожидаемый текст	**Распознанный текст**
Сәлеметсіз бе! Бүгін ауа райы тамаша.	Сәлеметсіз бе бүгін ауа-райы тамаша
Мен университетке бара жатырмын.	Мен университеке бара жатырмын
Біз жаңа жоба туралы сөйлестік.	Біз жаны жоба туралы сөйлестік

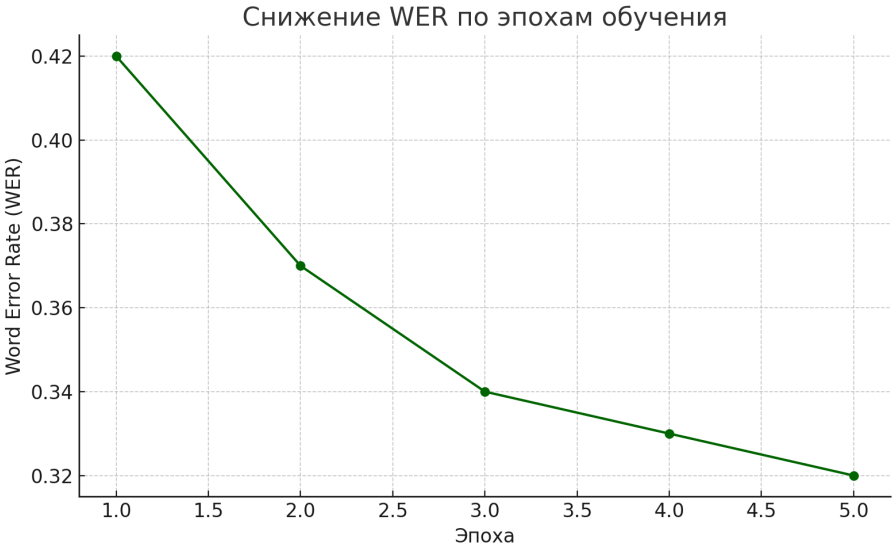

Рис. 2: Снижение Word Error Rate (WER) по эпохам обучения

Типичные ошибки модели

Анализ ошибок показал, что наиболее распространённые проблемы включают:

- Путаницу схожих по звучанию звуков и букв (*е* и *э*, *у* и *ұ*);
- Пропуски кратких слов или окончаний;
- Проблемы с диалектными особенностями и ударениями.

9 Заключение

В рамках данной курсовой работы была разработана и обучена модель автоматического распознавания казахской речи на базе архитектуры **Wav2Vec2**. Несмотря на ограниченные вычислительные ресурсы и небольшой объём обучающей выборки, модель продемонстрировала способность к адаптации под специфику казахского языка и показала приемлемые результаты по метрике WER.

Основные достижения работы:

- Проведён обзор существующих решений и анализ актуальности задачи распознавания казахской речи;
- Подобран и подготовлен корпус данных Common Voice 13.0;
- Адаптирована предобученная модель Wav2Vec2-large-xlsr-53 к казахской речи;
- Проведено обучение и анализ полученных результатов;
- Выявлены ограничения текущей реализации и предложены пути дальнейшего развития.

Разработанная система может быть использована в образовательных и медийных проектах, а также в рамках более широких систем голосового ввода и обработки информации на казахском языке. Полученные результаты подтверждают перспективность применения современных нейросетевых архитектур в задачах автоматического распознавания речи для малоресурсных языков.

Список использованных источников

1. Baevski A., Zhou Y., Mohamed A., Auli M. Wav2Vec 2.0: A framework for self-supervised learning of speech representations // arXiv preprint arXiv:2006.11477. — 2020.

2. Mozilla Common Voice: Open Source Multilingual Speech Dataset [Электронный ресурс]. — Режим доступа: `https://commonvoice.mozilla.org/` (дата обращения: 10.05.2025).

3. Hugging Face Transformers. Документация по модели Wav2Vec2 [Электронный ресурс]. — Режим доступа: `https://huggingface.co/transformers/model_doc/wav2vec2.html` (дата обращения: 10.05.2025).

4. PyTorch: Open Source Machine Learning Framework [Электронный ресурс]. — Режим доступа: `https://pytorch.org/` (дата обращения: 10.05.2025).

5. Schneider S., Baevski A., Collobert R., Auli M. Wav2Vec: Unsupervised Pre-training for Speech Recognition // arXiv preprint arXiv:1904.05862. — 2019.

6. Pratap V. et al. MLS: A Large-Scale Multilingual Dataset for Speech Research // Interspeech, 2020.